TAREA M54 – CD-YAIR PALOMARES

```
import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings("ignore")

import os
os.chdir("C:/Users/yair_/OneDrive/Desktop/Ciencia de Datos/Módulo 54 - Modelos de regresión lineal y series de tiempo")
```

```
#Se lee la base de datos y se convierte en dataframe
ventas = pd.read_csv("Cientifico de datos M53 - Advertising.csv")
ventas
```

	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	12.0
3	151.5	41.3	58.5	16.5
4	180.8	10.8	58.4	17.9
...	...	...	...	...
195	38.2	3.7	13.8	7.6
196	94.2	4.9	8.1	14.0
197	177.0	9.3	6.4	14.8
198	283.6	42.0	66.2	25.5
199	232.1	8.6	8.7	18.4

200 rows × 4 columns

```
#Se agrega el intercepto
ventas.insert(0, 'Intercepto', 1)
ventas
```

	Intercepto	TV	Radio	Newspaper	Sales
0	1	230.1	37.8	69.2	22.1
1	1	44.5	39.3	45.1	10.4
2	1	17.2	45.9	69.3	12.0
3	1	151.5	41.3	58.5	16.5
4	1	180.8	10.8	58.4	17.9
...	...	...	...	...	...
195	1	38.2	3.7	13.8	7.6
196	1	94.2	4.9	8.1	14.0
197	1	177.0	9.3	6.4	14.8
198	1	283.6	42.0	66.2	25.5
199	1	232.1	8.6	8.7	18.4

200 rows × 5 columns

```
#Definiendo las matrices
Xdata = ventas[["Intercepto", "TV", "Radio", "Newspaper"]].values
Ydata = ventas[["Sales"]].values
```

```
#Dividir en bases de entrenamiento y prueba
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(Xdata, Ydata, test_size = 0.3, random_state = 1)

x = x_train
y = y_train
```

```
#Opción de formato numérico para evitar que se coloquen decimales con notación científica
np.set_printoptions(formatter={"float_kind":"{:f}".format})
```

```python
#Reporte automatizada de la regresión en python
import statsmodels.api as sm

regressor = sm.OLS(y, x). fit()
print(regressor.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.899
Model:                            OLS   Adj. R-squared:                  0.897
Method:                 Least Squares   F-statistic:                     405.2
Date:                Mon, 23 Mar 2026   Prob (F-statistic):           1.36e-67
Time:                        17:13:35   Log-Likelihood:                -272.35
No. Observations:                 140   AIC:                             552.7
Df Residuals:                     136   BIC:                             564.5
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          4.6614      0.368     12.650      0.000       3.933       5.390
x1             0.0550      0.002     32.747      0.000       0.052       0.058
x2             0.1025      0.010      9.801      0.000       0.082       0.123
x3            -0.0015      0.007     -0.203      0.839      -0.016       0.013
==============================================================================
Omnibus:                       15.370   Durbin-Watson:                   2.041
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               25.876
Skew:                          -0.526   Prob(JB):                     2.41e-06
Kurtosis:                       4.824   Cond. No.                         432.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

```python
#Definiendo las matrices nuevamente, eliminando la variable de Newspaper.
Xdata = ventas[["Intercepto", "TV", "Radio"]].values
Ydata = ventas[["Sales"]].values
```

```python
#Dividir en bases de entrenamiento y prueba
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(Xdata, Ydata, test_size = 0.3, random_state = 1)

x = x_train
y = y_train
```

```python
#Reporte automatizada de la regresión en python
import statsmodels.api as sm

regressor = sm.OLS(y, x). fit()
print(regressor.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.899
Model:                            OLS   Adj. R-squared:                  0.898
Method:                 Least Squares   F-statistic:                     612.0
Date:                Mon, 23 Mar 2026   Prob (F-statistic):           4.95e-69
Time:                        17:16:22   Log-Likelihood:                -272.37
No. Observations:                 140   AIC:                             550.7
Df Residuals:                     137   BIC:                             559.6
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          4.6390      0.350     13.240      0.000       3.946       5.332
x1             0.0550      0.002     32.903      0.000       0.052       0.058
x2             0.1016      0.010     10.677      0.000       0.083       0.120
==============================================================================
Omnibus:                       14.841   Durbin-Watson:                   2.038
Prob(Omnibus):                  0.001   Jarque-Bera (JB):               24.663
Skew:                          -0.512   Prob(JB):                     4.41e-06
Kurtosis:                       4.783   Cond. No.                         407.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

```python
#Modo manual de aplicar la regresión
XT_X = np.matmul(np.matrix.transpose(x), x)
XT_X_inv = np.linalg.inv(XT_X)
XT_Y = np.matmul(np.matrix.transpose(x), y)
betas = np.matmul(XT_X_inv, XT_Y)
betas
```

```
array([[4.639009],
       [0.055005],
       [0.101644]])
```

```
#Ventas pronosticadas cuando se invierte 100 en TV, 50 en Radio y 70 en Periódicos (Ojo que la publicidad en periódicos no está en la ecuación)

#valores para el pronóstico
f = np.array([[1], [100], [50]])

#Pronóstico puntual
Pron_puntual = float(np.matmul(np.matrix.transpose(f), betas))
Pron_puntual
```

```
15.22167566487722
```

```
#Cálculos para obtener el margen de error
import math
import scipy.stats

Y_pred = np.matmul(x, betas)
Resid = y - Y_pred
RSS = np.matmul(np.matrix.transpose(Resid), Resid)
s_cuad = RSS / (len(y) - x.shape[1])
s = math.sqrt(s_cuad)

#Grados de libertad: n - (k+1)
grados_libertad = len(y) - x.shape[1]
confianza = 0.90
q = (1 - confianza) / 2
t_critico = abs(scipy.stats.t.ppf(q, df=grados_libertad))

Margen_error = t_critico * (s * (float(np.matmul(np.matmul(np.matrix.transpose(f), XT_X_inv), f)) ** 0.5))
Margen_error
```

```
np.float64(0.5034711983440173)
```

```
#Límites del intervalo de confianza para el pronóstico puntual
Lim_inferior = Pron_puntual - Margen_error
Lim_superior = Pron_puntual + Margen_error
print("Intervalo de confianza: (", Lim_inferior, ",", Lim_superior, ")")
```

```
Intervalo de confianza: ( 14.718204466533201 , 15.725146863221237 )
```

Validación de los supuestos del modelo

```
import scipy
#Cálculo de la asimetría en residuales
skew = float(scipy.stats.skew(Resid, bias=True))
print("La asimetría de los residuales es:", skew)
#Cálculo de la curtosis de residuales
kurtosis = float(scipy.stats.kurtosis(Resid, fisher=False))
print("La kurtosis de los residuales es:", kurtosis)
Jarque_Bera = (len(y)/6) * (skew**2 + (kurtosis-3)**2 / 4)
print("Valor del estadístico de Jarque Bera:", Jarque_Bera)
Nivel_confianza = 0.90
valor_chi2 = scipy.stats.chi2.ppf(Nivel_confianza, df = 2)
print("Valor crítico chi-cuadrada para la prueba de hipótesis", valor_chi2)
```

```
La asimetría de los residuales es: -0.5124182186793582
La kurtosis de los residuales es: 4.782590640126675
Valor del estadístico de Jarque Bera: 24.662861496031123
Valor crítico chi-cuadrada para la prueba de hipótesis 4.605170185988092
```

Conclusión: Dado que JB si es mayor al nivel crítico, se rechaza la hipótesis nula. Es decir, los residuales no se comportan bajo una distribución normal.

No se cumple el supuesto de normalidad.

```
from statsmodels.formula.api import ols
y_df = pd.DataFrame(y)
x_df = pd.DataFrame(x[:,1:3])
df = pd.concat([y_df, x_df.reindex(y_df.index)], axis = 1)
df.columns = ["Y", "X1", "X2"]
df
```

	Y	X1	X2
0	12.2	139.2	14.3
1	13.4	139.3	14.5
2	5.3	5.4	29.9
3	20.7	293.6	27.7
4	24.4	281.4	39.6
...	...	...	...
135	19.6	219.8	33.5
136	20.8	273.7	28.9
137	8.8	26.8	33.0
138	10.9	73.4	17.0
139	14.7	74.7	49.4

140 rows × 3 columns

```python
# Ajuste de regresión lineal múltiple
model = ols('Y ~ X1 + X2', data = df).fit()

from statsmodels.stats.stattools import durbin_watson

#Prueba de Durbin-Watson
durbin_watson(model.resid)
```

```
np.float64(2.0375161916374998)
```

Conclusión: Ddao que el valor de DW es cercano a 2, se concluye que no existe autocorrelación entre los residuales. Es decir, los errores son independientes entre sí.

Se cumple el supuesto de inexistencia de autocorrelación entre los residuales.

```python
Resid_cuad = Resid ** 2
Resid_cuad = pd.DataFrame(Resid_cuad)

X1 = df.iloc[:,1]
X1_df = pd.DataFrame(X1)

X1cuad = X1 ** 2
X1cuad_df = pd.DataFrame(X1cuad)

X2 = df.iloc[:,2]
X2_df = pd.DataFrame(X2)

X2cuad = X2 ** 2
X2cuad_df = pd.DataFrame(X2cuad)

df_Aux = pd.concat([Resid_cuad, X1_df.reindex(y_df.index), X1cuad_df.reindex(y_df.index), X2_df.reindex(y_df.index), X2cuad_df.reindex(y_df.index)], axis
df_Aux.columns = ['Residual', 'X1', 'X1cuad', 'X2', 'X2cuad']
df_Aux
```

	Residual	X1	X1cuad	X2	X2cuad
0	2.399962	139.2	19376.64	14.3	204.49
1	0.140633	139.3	19404.49	14.5	210.25
2	7.156605	5.4	29.16	29.9	894.01
3	8.432907	293.6	86200.96	27.7	767.29
4	0.066332	281.4	79185.96	39.6	1568.16
...	...	...	...	...	...
135	0.285292	219.8	48312.04	33.5	1122.25
136	3.353748	273.7	74911.69	28.9	835.21
137	0.445398	26.8	718.24	33.0	1089.00
138	0.245714	73.4	5387.56	17.0	289.00
139	0.866634	74.7	5580.09	49.4	2440.36

140 rows × 5 columns

```
#Ajuste de regresión lineal múltiple
modelAux = ols('Residual ~ X1 + X2 + X1cuad + X2cuad + (X1*X2)', data = df_Aux).fit()
RSqAux = modelAux.rsquared
Estadístico = len(y) * RSqAux
print("Valor estadístico:", Estadístico)
Nivel_confianza = 0.90
valor_chi2 = scipy.stats.chi2.ppf(Nivel_confianza, df = 5)
print("El valor estadístico chi-cuadrada es:", valor_chi2)
```

```
Valor estadístico: 11.353378151633503
El valor estadístico chi-cuadrada es: 9.236356899781123
```

Conclusión: Al superar el valor crítico de nuestro estadístico de prueba, hay evidencia suficiente de Heterocedasticidad, por lo que se puede considerar que hay desigualdad entre las varianzas de los residuales.

No se cumple el supuesto de Homocedasticidad

```python
# Alternativa para la prueba de White
from statsmodels.stats.diagnostic import het_white

white_test = het_white(model.resid, model.model.exog)
print("Estadístico de prueba:", white_test[0])
print("Valor p:", white_test[1])
```

```
Estadístico de prueba: 11.353378151633706
Valor p: 0.04480664163871973
```

No se cumple el supuesto de Homocedasticidad

```python
import seaborn as sns
import matplotlib.pyplot as plt

#Análisis de correlaciones entre las variables para identificar colinealidad
corr = ventas[["TV", "Radio"]].corr(numeric_only=True)

plt.figure(figsize=(10,8))
sns.heatmap(corr, cmap="coolwarm", annot=True, fmt=".2f")
plt.show()
```

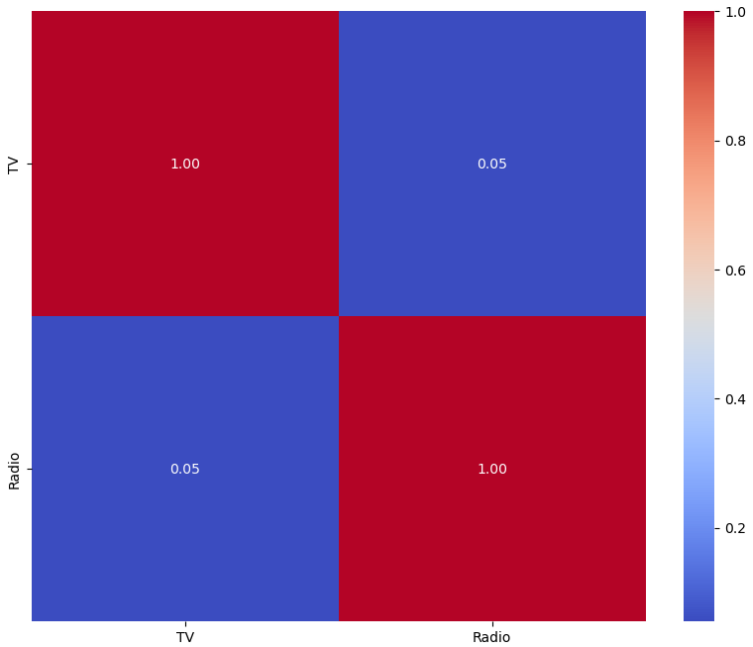

Conclusión: Las dos variables independientes utilizadas en el modelo, no presentan multicolinealidas.

Cálculo manual de Sesgo, Curtosis y Estadístico de Durbin Watson

```
#Cálculos para la asimetría
Mu_3 = ((Resid - Resid.mean())**3).sum() / len(Resid)
sigma_3 = (((Resid - Resid.mean())**2).sum() / len(Resid))**(3/2)
Sesgo = Mu_3/sigma_3
print(Sesgo)
```

```
-0.5124182186793583
```

```
#Cálculos para la curtosis
Mu_4 = ((Resid - Resid.mean())**4).sum() / len(Resid)
sigma_4 = (((Resid - Resid.mean())**2).sum() / len(Resid))**2
Curtosis = Mu_4/sigma_4
print(Curtosis)
```

```
4.782590640126675
```

```
#Cálculo del estadístico Durbin Watson
aux = 0
for i in range(1,len(Resid)):
    aux = aux + (Resid[i][0] - Resid[i-1][0])**2
Durbin = aux / (Resid**2).sum()
print(Durbin)
```

```
2.037516191637498
```